



Εθνικό Μετσόβιο Πολυτεχνείο
Σχολή Ηλεκτρολόγων Μηχανικών και Μηχανικών
Υπολογιστών
Τομέας Τεχνολογίας Πληροφορικής & Υπολογιστών

Αυτοματοποιημένος Μαθηματικός Συλλογισμός και Ανάλυση Αριθμητικής Σταθερότητας με Χρήση LLMs στη Γλώσσα Lean

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

Ονοματεπώνυμο: Γεώργιος Αλέξανδρος Γεωργαντζάς
ΑΜ: 03120017

Επιβλέπουσα: Ζωή Παρασκευοπούλου

Αθήνα, April 6, 2026

Contents

1	Εισαγωγή	2
1.1	Κίνητρο	2
1.2	Συνεισφορά	2
1.3	Δομή της εργασίας	3
2	Θεωρητικό Υπόβαθρο	4
2.1	Αριθμητική κινητής υποδιαστολής	4
2.2	Το πλαίσιο του Higham	4
2.3	Lean 4 και Mathlib	4
3	Η Βιβλιοθήκη lean-fp-analysis	4
3.1	Σχεδίαση του FPModel	4
3.2	Gamma calculus	4
3.3	Kernel contracts	4
3.4	Αρχιτεκτονική modules	4
4	Μελέτη Σύνθεσης	4
5	Σύγκριση και Ανάλυση	4
5.1	Σύγκριση με LAPProof (Coq)	4
5.2	Κόστος απόδειξης και εκφραστικότητα	4
6	Αξιολόγηση LLM	4
6.1	Ερευνητικό ερώτημα	4
6.2	Πειραματική διάταξη	4
6.3	Αποτελέσματα	4
6.4	Συζήτηση	4
7	Συμπεράσματα	4
7.1	Συνεισφορές	4
7.2	Περιορισμοί	4
7.3	Μελλοντική εργασία	4

1 Εισαγωγή

1.1 Κίνητρο

Η αριθμητική κινητής υποδιαστολής (floating-point arithmetic) αποτελεί τη βάση σχεδόν κάθε επιστημονικού υπολογισμού, από την αριθμητική γραμμική άλγεβρα μέχρι τη μηχανική μάθηση και τις προσομοιώσεις φυσικών συστημάτων. Ωστόσο, κάθε αριθμητική πράξη σε κινητή υποδιαστολή εισάγει σφάλμα στρογγυλοποίησης, και η συσσώρευση τέτοιων σφαλμάτων μπορεί να οδηγήσει σε αριθμητικά ασταθείς αλγορίθμους — αλγορίθμους, δηλαδή, των οποίων τα αποτελέσματα αποκλίνουν σημαντικά από τις ακριβείς μαθηματικές λύσεις.

Το κλασικό πλαίσιο ανάλυσης σφαλμάτων στρογγυλοποίησης, όπως αναπτύχθηκε από τον Wilkinson [Wil63] και κωδικοποιήθηκε συστηματικά από τον Higham [Hig02], παρέχει αυστηρά φράγματα (error bounds) για forward και backward σφάλμα ενός μεγάλου εύρους αλγορίθμων. Παρά την αυστηρότητα αυτών των αποδείξεων, παραμένουν μέχρι σήμερα κατά κύριο λόγο αποδείξεις σε χαρτί: εκτεταμένες, με πολλά ενδιάμεσα βήματα, και ευάλωτες σε λεπτά λάθη που ξεφεύγουν κατά τη χειρόγραφη επαλήθευση.

Η τυπική επαλήθευση (formal verification) μέσω proof assistants προσφέρει μια ριζικά διαφορετική προσέγγιση: τη μηχανική πιστοποίηση κάθε βήματος μιας απόδειξης. Στο πεδίο της αριθμητικής κινητής υποδιαστολής, η βιβλιοθήκη Flocq [BM11] στο σύστημα Coq απέδειξε ότι η τυπική επαλήθευση ιδιοτήτων στρογγυλοποίησης είναι εφικτή, ενώ πρόσφατα η βιβλιοθήκη LAProof [KATB23] τυποποίησε φράγματα σφαλμάτων για πυρήνες BLAS (εσωτερικό γινόμενο, πολλαπλασιασμό πινάκων κ.ά.), επίσης σε Coq.

Ωστόσο, υπάρχει ένα σημαντικό κενό. Η LAPProof καλύπτει αποκλειστικά πυρήνες BLAS — δηλαδή μεμονωμένες αριθμητικές πράξεις — χωρίς να επεκτείνεται σε σύνθετους αλγορίθμους όπως η παραγοντοποίηση LU, η μέθοδος Cholesky, η επαναληπτική βελτίωση (iterative refinement), ή η εκτίμηση δεικτών ευστάθειας (condition number estimation). Επιπλέον, η δομή της δεν υποστηρίζει τη σύνθεση φραγμάτων — τη δυνατότητα, δηλαδή, να συνδυάζονται τα contracts μεμονωμένων πυρήνων για την παραγωγή φραγμάτων ολόκληρων αλγορίθμων.

Παράλληλα, η ανάδυση μεγάλων γλωσσικών μοντέλων (LLMs) ως εργαλείων αυτοματοποιημένου μαθηματικού συλλογισμού ανοίγει νέες προοπτικές. Συστήματα όπως το Aristotle [Har25] έχουν δείξει εντυπωσιακή ικανότητα στην αυτόματη παραγωγή αποδείξεων στη γλώσσα Lean 4 [dMU21]. Ένα φυσικό ερώτημα είναι κατά πόσο τέτοια μοντέλα μπορούν να αξιοποιήσουν μια εξειδικευμένη βιβλιοθήκη τυπικής επαλήθευσης ως πλαίσιο αναφοράς, μειώνοντας δραστικά τον ανθρώπινο κόπο απόδειξης.

1.2 Συνεισφορά

Η παρούσα διπλωματική εργασία παρουσιάζει τη βιβλιοθήκη `lean-fp-analysis`: την πρώτη επαναχρησιμοποιήσιμη βιβλιοθήκη τυπικής επαλήθευσης αριθμητικής σταθερότητας στη γλώσσα Lean 4, βασισμένη στο σύστημα τύπων της Mathlib [The20]. Οι κύριες συνεισφορές είναι:

1. **Αξιοματικό μοντέλο κινητής υποδιαστολής (FPModel).** Σχεδιασμός ενός αφηρημένου μοντέλου αριθμητικής κινητής υποδιαστολής σε Lean 4, ανεξάρτητου από συγκεκριμένη αναπαράσταση (IEEE 754 κ.ά.) [IEE19], που αποτυπώνει τα βασικά αξιώματα στρογγυλοποίησης και επιτρέπει ανάλυση σε αυθαίρετη ακρίβεια.
2. **Εκτεταμένη τυποποίηση του Higham.** Τυποποίηση φραγμάτων σφαλμάτων για 17 κεφάλαια του Higham [Hig02], καλύπτοντας: πυρήνες BLAS (εσωτερικό

γινόμενο, εξωτερικό γινόμενο, πολλαπλασιασμό πίνακα-διανύσματος, πολλαπλασιασμό πινάκων), αλγορίθμους άθροισης, θεωρία διαταραχής, επίλυση τριγωνικών συστημάτων, παραγοντοποίηση LU (συμπεριλαμβανομένης block LU), παραγοντοποίηση Cholesky, επαναληπτική βελτίωση, αντιστροφή πινάκων και Gauss–Jordan, εκτίμηση δεικτών ευστάθειας, εξίσωση Sylvester, στάσιμες επαναληπτικές μεθόδους, και δυνάμεις πινάκων — σύνολο περίπου 600 ορισμών και θεωρημάτων, χωρίς κανένα sorry.

3. **Σύνθεση φραγμάτων (compositionality).** Αρχιτεκτονική kernel contracts που επιτρέπει τη σύνθεση φραγμάτων μεμονωμένων πυρήνων σε end-to-end φράγματα σφαλμάτων για σύνθετους αλγορίθμους (π.χ. από LU + forward/back substitution σε LU solve).
4. **Αξιολόγηση LLM.** Σχεδιασμός και εκτέλεση πειράματος αξιολόγησης μεγάλων γλωσσικών μοντέλων στην αυτόματη παραγωγή αποδείξεων αριθμητικής σταθερότητας σε Lean 4. Το πείραμα περιλαμβάνει 10 εργασίες σε 3 επίπεδα δυσκολίας, υπό 3 συνθήκες (χωρίς βοήθεια, με αξιώματα, με πλήρη βιβλιοθήκη), εξετάζοντας κατά πόσο η ύπαρξη μιας εξειδικευμένης βιβλιοθήκης μειώνει τον κόπο απόδειξης.

1.3 Δομή της εργασίας

Η εργασία οργανώνεται ως εξής. Στο Κεφάλαιο 2 παρουσιάζεται το θεωρητικό υπόβαθρο: αριθμητική κινητής υποδιαστολής, το αναλυτικό πλαίσιο του Higham, και τα βασικά χαρακτηριστικά της γλώσσας Lean 4 και της βιβλιοθήκης Mathlib. Στο Κεφάλαιο 3 περιγράφεται η αρχιτεκτονική της βιβλιοθήκης `lean-fp-analysis`: το αξιωματικό μοντέλο FP-Model, ο gamma calculus, τα kernel contracts, και η δομή των modules. Στο Κεφάλαιο 4 παρουσιάζεται μια μελέτη σύνθεσης, όπου αποδεικνύεται η δυνατότητα σύνθεσης φραγμάτων μεμονωμένων πυρήνων σε φράγμα ολόκληρου αλγορίθμου. Στο Κεφάλαιο 5 πραγματοποιείται σύγκριση με τη βιβλιοθήκη LAMepp σε Coq, καθώς και ανάλυση του κόστους απόδειξης και της εκφραστικότητας κάθε προσέγγισης. Στο Κεφάλαιο 6 περιγράφεται το πείραμα αξιολόγησης LLM και τα αποτελέσματά του. Τέλος, στο Κεφάλαιο 7 συνοψίζονται οι συνεισφορές, αναλύονται οι περιορισμοί, και προτείνονται κατευθύνσεις μελλοντικής εργασίας.

2 Θεωρητικό Υπόβαθρο

2.1 Αριθμητική κινητής υποδιαστολής

2.2 Το πλαίσιο του Higham

2.3 Lean 4 και Mathlib

3 Η Βιβλιοθήκη lean-fp-analysis

3.1 Σχεδίαση του FPModel

3.2 Gamma calculus

3.3 Kernel contracts

3.4 Αρχιτεκτονική modules

4 Μελέτη Σύνθεσης

5 Σύγκριση και Ανάλυση

5.1 Σύγκριση με LAProof (Coq)

5.2 Κόστος απόδειξης και εκφραστικότητα

6 Αξιολόγηση LLM

6.1 Ερευνητικό ερώτημα

6.2 Πειραματική διάταξη

6.3 Αποτελέσματα

6.4 Συζήτηση

7 Συμπεράσματα

7.1 Συνεισφορές

7.2 Περιορισμοί

7.3 Μελλοντική εργασία

Βιβλιογραφία

- [BM11] Sylvie Boldo and Guillaume Melquiond. Flocq: A unified library for proving floating-point algorithms in Coq. *Proceedings of the 20th IEEE Symposium on Computer Arithmetic (ARITH)*, pages 243–252, 2011.
- [Dem97] James W. Demmel. *Applied Numerical Linear Algebra*. SIAM, 1997.
- [dMU21] Leonardo de Moura and Sebastian Ullrich. The Lean 4 theorem prover and programming language. In *Proceedings of the 28th International Conference on Automated Deduction (CADE-28)*, pages 625–635. Springer, 2021.
- [GRA⁺26] Fabian Gloeckle, Amine Rammal, Thomas Arnal, Rémi Munos, Vivien Cabannes, Gabriel Synnaeve, and Syed Ahmad Hayat. Automatic textbook formalization, 2026. Preprint. Code: <https://github.com/facebookresearch/repoprover>.
- [Har25] Harmonic. Aristotle: Scaling lean 4 theorem proving with reinforcement learning. Technical Report, Harmonic Inc., 2025.
- [Hig02] Nicholas J. Higham. *Accuracy and Stability of Numerical Algorithms*. SIAM, 2nd edition, 2002.
- [HZW25] Jiewen Hu, Thomas Zhu, and Sean Welleck. miniCTX: Neural theorem proving with (long-)Contexts. In *International Conference on Learning Representations (ICLR)*, 2025.
- [IEE19] IEEE. IEEE standard for floating-point arithmetic (IEEE std 754-2019). IEEE Std 754-2019, 2019.
- [KATB23] Ariel E. Kellison, Andrew W. Appel, Mohit Tekriwal, and David Bindel. LAProof: A library of formal proofs of accuracy and correctness for linear algebra programs. In *30th IEEE Symposium on Computer Arithmetic (ARITH)*, pages 127–134. IEEE, 2023.
- [The20] The mathlib Community. The Lean mathematical library. *Proceedings of the 9th ACM SIGPLAN International Conference on Certified Programs and Proofs (CPP)*, pages 367–381, 2020.
- [Wil63] James H. Wilkinson. *Rounding Errors in Algebraic Processes*. Prentice-Hall, 1963.